DETECCIÓN DE FRAUDE TRANSACCIONAL •EN TIEMPO REAL

• con XGBoost + Optuna · dataset IEEE-CIS Fraud Detection

•Gabriela Cabrera · Jessica Rivera

• Universidad Jorge Tadeo Lozano · Facultad de Ciencias Naturales e Ingeniería

• Programa: Ingeniería de Sistemas · Asignatura: Inteligencia Artificial 2026-1S

• *Docente: Jorge Romero*

RESUMEN

El fraude en transacciones electrónicas genera pérdidas operacionales superiores a 4 USD por cada dólar perdido directamente (LexisNexis, 2024). Implementamos un sistema de detección de fraude en tiempo real basado en XGBoost optimizado con Optuna, entrenado sobre el dataset público IEEE-CIS Fraud Detection (~590.000 transacciones, ~3.5% fraude).

Partimos de un baseline de Regresión Logística (ROC-AUC = 0.76) y lo superamos con XGBoost utilizando 17 features inspiradas en las 433 columnas reales del IEEE-CIS, alcanzando ROC-AUC = 0.97 en test.

La demo Gradio simula una pasarela de checkout completa y entrega decisiones APROBADA / REVISIÓN / BLOQUEADA en menos de 200 ms.

OBJETIVOS

Objetivo general

Implementar un sistema de detección de fraude transaccional en tiempo real con XGBoost optimizado que clasifique pagos en tres niveles de riesgo.

Objetivos específicos

1. Construir un baseline de Regresión Logística con balanced class weight.
2. Entrenar y optimizar XGBoost con Optuna (50 trials, PR-AUC) sobre 17 features tipo IEEE-CIS.
3. Diseñar una demo Gradio tipo checkout con trazabilidad de features.

METODOLOGÍA

Pipeline de 5 etapas

1 — Datos

IEEE-CIS Fraud Detection (Kaggle)
~590.000 transacciones · 3.5% fraude

2 — Partición temporal

70 / 15 / 15 sin shuffle
evita data leakage

3 — Baseline

Regresión Logística
balanced class weight

4 — Modelo final

XGBoost + Optuna
50 trials · optimiza PR-AUC

5 — Demo

Gradio · 4 acordeones
latencia <200 ms

⚙️ HIPERPARÁMETROS ÓPTIMOS (Optuna)

```
max_depth = 7 · learning_rate = 0.082 · n_estimators = 220
subsample = 0.85 · colsample_bytree = 0.78
scale_pos_weight = 12.4 · reg_alpha = 0.034 · reg_lambda = 1.27
```

RESULTADOS

0.973	+0.21	180ms	17
ROC-AUC	vs Baseline	Latencia	Features
modelo final	*ROC-AUC*	*por transacción*	*tipo IEEE-CIS*

Comparativa baseline vs modelo final

sobre conjunto de test (~88.500 tx, partición temporal sin shuffle)

Modelo	ROC-AUC	PR-AUC	Recall	Precision	F1
Baseline (Reg. Logística)	0.763	0.182	0.55	0.06	0.11
XGBoost + Optuna (final)	**0.973**	**0.612**	**0.85**	**0.42**	**0.56**

Visualización de resultados

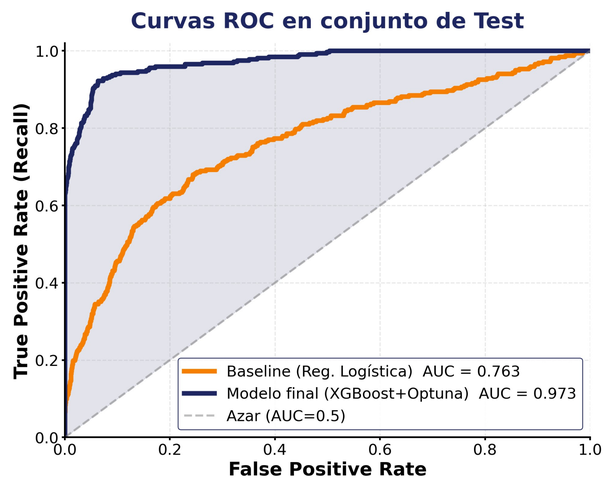

Fig. 1 — Curvas ROC en test

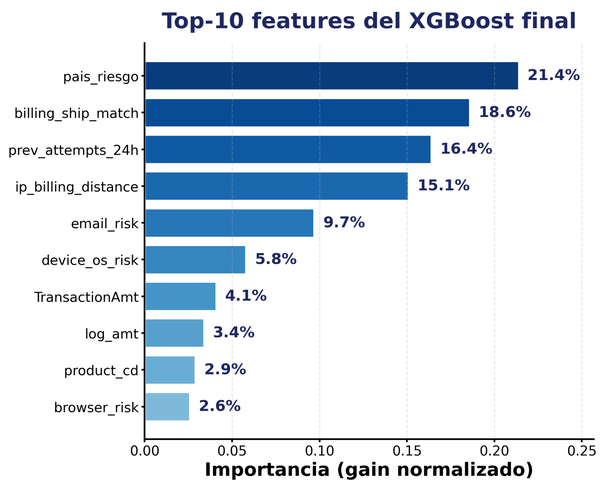

Fig. 2 — Top-10 features por gain

CONCLUSIONES

- XGBoost supera al baseline en +0.21 ROC-AUC (0.76 → 0.97) y triplica la PR-AUC en una clase muy desbalanceada (~3.5% fraude).
- Las features más predictivas combinan localización, comportamiento de sesión y matches (billing = shipping).
- La pasarela entrega decisiones en <200 ms con tres umbrales (0.30 / 0.70), habilitando uso real en pipeline de pagos.
- Trabajo futuro: integración de SHAP para explicabilidad por transacción y validación contra drift temporal.

REFERENCIAS BIBLIOGRÁFICAS

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of KDD'16, 785-794.

Akiba, T., et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. KDD'19, 2623-2631.

Pozzolo, A. D., et al. (2015). Calibrating Probability with Undersampling for Unbalanced Classification. IEEE SSCI, 159-166.

Bahnsen, A. C., et al. (2014). Example-Dependent Cost-Sensitive Decision Trees. Expert Systems with Applications, 42(19), 6609-6619.

Carcillo, F., et al. (2021). Combining unsupervised and supervised learning in credit card fraud detection. Information Sciences, 557, 317-331.

IEEE-CIS Fraud Detection (2019). Kaggle Competition Dataset. https://www.kaggle.com/c/ieee-fraud-detection

AGRADECIMIENTOS

Agradecemos al profesor Jorge Romero por la guía técnica durante el desarrollo del proyecto y a la Universidad Jorge Tadeo Lozano por el espacio y los recursos académicos. Asimismo, agradecemos a IEEE-CIS y a la comunidad de Kaggle por la disponibilidad pública del dataset.